ИТМО

РГР 3

Регрессионные модели и их интерпретация

1 Цель работы

Регрессия помогает увидеть закономерность там, где сначала видны только точки

Цель работы — оценить функцию регрессии и сравнить несколько моделей зависимости результативного признака от одного фактора

ЭТАПЫ РАБОТЫ

- Первичный анализ данных и диаграмма рассеяния
- Построение трёх регрессионных моделей
- Сравнение качества аппроксимации
- Статистический анализ линейной модели
- Прогноз и содержательная интерпретация

2 Исходные данные и условия варианта

У каждой зависимости есть свой контекст

CSV-файл варианта содержит два столбца: x — фактор, y — результат

- Вариант задаёт предметную область и источник данных
- Указывается правило получения среза, если используется подмножество
- Для сравнения обязательны три модели:
  - линейная: $y = a + bx$
  - квадратичная: $y = a + bx + cx^2$
  - дополнительная модель из карточки варианта
- Для заданного x^* требуется получить прогноз

3 Общая схема исследования

От данных — к модели, от модели — к выводу

данные → график → модели → качество → прогноз → выводы

- ❑ Загружаем данные и описываем источник
- ❑ Строим диаграмму рассеяния и формулируем гипотезу о связи
- ❑ Оцениваем параметры трёх моделей
- ❑ Сравниваем R^2, ошибку аппроксимации и остатки
- ❑ Выбираем модель для прогноза и объясняем результат

4 Первичный анализ данных

График часто говорит раньше формул

Начинаем с загрузки CSV и описания источника данных

- ❑ Загрузить значения x и y
- ❑ Указать набор данных и правило среза
- ❑ Построить диаграмму рассеяния (x_i, y_i)
- ❑ Описать направление и предполагаемую форму связи

5 Линейная модель

Простая модель — не значит слабая модель

Базовая модель зависимости: $y = a + bx$

- Оценить a и b методом наименьших квадратов
- Записать итоговое уравнение регрессии
- Построить линию на фоне исходных точек
- Получить прогнозные значения $\hat{y}_i$
- Найти остатки $e_i = y_i - \hat{y}_i$ и $RSS = \Sigma e_i^2$

6 Квадратичная модель

Иногда данным нужно чуть больше изгиба

Модель учитывает возможную кривизну зависимости:

$$y = a + bx + cx^2$$

- ❑ Оценить параметры a, b, c
- ❑ Построить параболу на диаграмме рассеяния
- ❑ Получить прогнозы для всех наблюдений
- ❑ Проверить, даёт ли усложнение выигрыш по качеству

7 Дополнительная модель

Проверяем ещё один взгляд на зависимость

В карточке варианта назначается одна модель из четырёх

- Показательная
- Степенная
- Полулогарифмическая
- Гиперболическая

При необходимости выполнить линеаризацию и проверить область допустимых значений

8 Сравнение моделей

Сравниваем не обещания, а качество приближения

Лучшая модель выбирается не только по одному числу

- ❑ Вычислить коэффициент детерминации R^2
- ❑ Найти среднюю ошибку аппроксимации
- ❑ Проанализировать графики остатков
- ❑ Учесть содержательную осмысленность модели
- ❑ Сделать вывод, какая модель лучше описывает зависимость

9 Шкала оценивания

Элемент работы	Баллы
Описание источника данных, среза и первичный анализ	2
Построение линейной модели и интерпретация	3
Построение квадратичной модели	2
Построение дополнительной модели	2
Сравнение моделей и выбор лучшей	3
Статистический анализ линейной модели	2
Прогноз и итоговый вывод	1
Итого	**15**

10 Подробный анализ линейной модели

Статистическая значимость превращает оценку обоснованный вывод

- Рассчитать оценки $\hat{a}$ и $\hat{b}$
- Получить прогнозы $\hat{y}_i$ и остатки e_i
- Вычислить RSS, $s^2 = RSS/(n-2)$ и s
- Построить 95% доверительные интервалы для коэффициентов
- Проверить гипотеза H_0: $b = 0$ против H_1: $b \neq 0$ при $\alpha = 0.05$
- Сделать вывод о статистической значимости коэффициента при x

11 Ожидаемые результаты

Собираем результаты в одну понятную историю

- Построены три регрессионные модели для реальных данных
- Для каждой модели записано уравнение и получены прогнозы
- Качество моделей сравнено по R^2, ошибке аппроксимации и остаткам
- Выбранная модель использована для прогноза при заданном x*
- Итоговый вывод объясняет зависимость на языке предметной области

Спасибо
за внимание!

ITMO more than a UNIVERSITY