Министерство науки и высшего образования Российской Федерации
ФГАОУ ВО «Национальный исследовательский университет ИТМО»

Расчётно-графическая работа №3

Регрессионные модели и их интерпретация

Вариант: А-10
Предмет: Математическая статистика
Выполнили: Михайлов П. С. и Гришин А. Е.

25 мая 2026 г.

Содержание

1 Описание данных и первичный анализ **2**
1.1 Источник данных 2
1.2 Описательные статистики 2
1.3 Диаграмма рассеяния и гипотеза о связи 3

2 Построение трёх регрессионных моделей **4**
2.1 Линейная модель 4
2.2 Квадратичная модель 4
2.3 Степенная модель 6
2.4 Графики трёх моделей 7

3 Сравнение моделей **8**

4 Статистический анализ линейной модели **9**
4.1 Остатки и оценка дисперсии 9
4.2 Стандартные ошибки и доверительные интервалы 9
4.3 Проверка значимости коэффициента при x 10
4.4 Графики остатков 10

5 Прогноз при $x^* = 2{,}9672$ ГГц **12**

6 Итоговый вывод **13**

1. Описание данных и первичный анализ

1.1. Источник данных

Для варианта А-10 используется набор данных **openintro::cpu** (CPU's Released between 2010 and 2020) из пакета `openintro` языка R. Источник: `https://vincentarelbundock.github.io/Rdatasets/doc/openintro/cpu.html`.

Из полного набора оставлены наблюдения без пропусков в столбце `boost_clock`. Используются два столбца: `base_clock` (базовая частота процессора в ГГц) — фактор x, и `boost_clock` (boost-частота процессора в ГГц) — отклик y. Число наблюдений $n = 60$.

Прикладной контекст: по базовой тактовой частоте процессора оценивается его максимальная (boost) частота, что позволяет сравнивать архитектуры и прогнозировать производительность без полного тестирования.

1.2. Описательные статистики

Таблица 1: Основные описательные статистики

Показатель	x, ГГц	y, ГГц
Минимум	0,700	1,500
Максимум	4,700	5,000
Среднее	2,748	3,707

1.3. Диаграмма рассеяния и гипотеза о связи

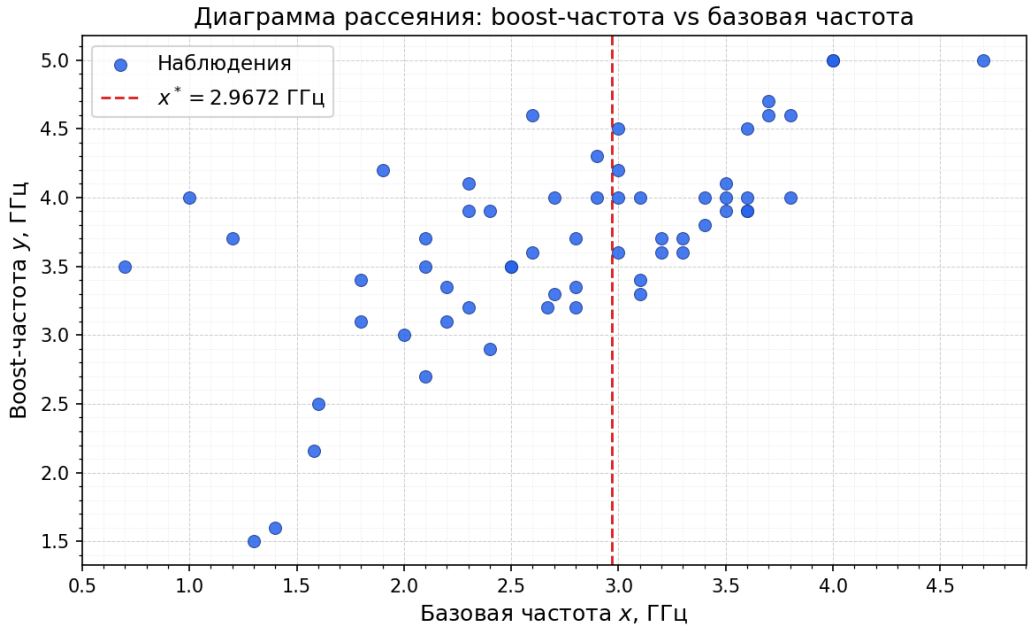


Рис. 1: Диаграмма рассеяния $(x_i,\, y_i)$. Пунктир — прогнозное значение $x^* = 2{,}9672$ ГГц.

По диаграмме рассеяния видна положительная связь: чем выше базовая частота, тем выше boost-частота. Разброс умеренный, характер связи близок к линейному, однако при малых x наблюдается некоторое увеличение дисперсии. Гипотеза: существует монотонно возрастающая регрессионная зависимость y от x.

2. Построение трёх регрессионных моделей

2.1. Линейная модель

Модель имеет вид $\hat{y} = a + bx$. Оценки МНК:

$$S_{xx} = \sum_{i=1}^{n}(x_i - \bar{x})^2 = 52{,}091993, \qquad S_{xy} = \sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = 29{,}488680,$$

$$\hat{b} = \frac{S_{xy}}{S_{xx}} = \frac{29{,}488680}{52{,}091993} = 0{,}566164, \qquad \hat{a} = \bar{y} - \hat{b}\,\bar{x} = 3{,}707 - 0{,}566164 \cdot 2{,}748 = 2{,}142160.$$

Итоговое уравнение:

$$\hat{y} = 2{,}1422 + 0{,}5662\,x.$$

При увеличении базовой частоты на 1 ГГц boost-частота в среднем возрастает на 0,566 ГГц. Свободный член $a = 2{,}142$ ГГц интерпретируется как условный уровень boost-частоты при нулевой базовой частоте (экстраполяция за пределы наблюдений).

2.2. Квадратичная модель

Модель имеет вид $\hat{y} = b_0 + b_1 x + b_2 x^2$. Для нахождения параметров b_0, b_1, b_2 методом наименьших квадратов (МНК) минимизируется функция потерь — сумма квадратов остатков:

$$S(b_0, b_1, b_2) = \sum_{i=1}^{n} \left(y_i - (b_0 + b_1 x_i + b_2 x_i^2)\right)^2 \to \min.$$

Необходимым условием экстремума функции является равенство нулю её частных производных по всем оцениваемым параметрам:

$$\begin{cases} \dfrac{\partial S}{\partial b_0} = -2\displaystyle\sum_{i=1}^{n}\left(y_i - b_0 - b_1 x_i - b_2 x_i^2\right) = 0, \\ \dfrac{\partial S}{\partial b_1} = -2\displaystyle\sum_{i=1}^{n} x_i\left(y_i - b_0 - b_1 x_i - b_2 x_i^2\right) = 0, \\ \dfrac{\partial S}{\partial b_2} = -2\displaystyle\sum_{i=1}^{n} x_i^2\left(y_i - b_0 - b_1 x_i - b_2 x_i^2\right) = 0. \end{cases}$$

После деления на -2 и переноса свободных членов в правую часть

получаем систему нормальных уравнений МНК:

$$\begin{cases} b_0 \cdot n + b_1 \cdot \sum x_i + b_2 \cdot \sum x_i^2 = \sum y_i, \\ b_0 \cdot \sum x_i + b_1 \cdot \sum x_i^2 + b_2 \cdot \sum x_i^3 = \sum x_i y_i, \\ b_0 \cdot \sum x_i^2 + b_1 \cdot \sum x_i^3 + b_2 \cdot \sum x_i^4 = \sum x_i^2 y_i. \end{cases}$$

В матричной форме система записывается как $\mathbf{X}^\top \mathbf{X}\,\mathbf{b} = \mathbf{X}^\top \mathbf{y}$. Для её аналитического решения применяется метод Крамера:

$$b_0 = \frac{\Delta_0}{\Delta}, \qquad b_1 = \frac{\Delta_1}{\Delta}, \qquad b_2 = \frac{\Delta_2}{\Delta},$$

где главный определитель системы Δ и побочные определители $\Delta_0, \Delta_1, \Delta_2$ формируются из матриц сумм:

$$\Delta = \begin{vmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{vmatrix}, \quad \Delta_0 = \begin{vmatrix} \sum y_i & \sum x_i & \sum x_i^2 \\ \sum x_i y_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 y_i & \sum x_i^3 & \sum x_i^4 \end{vmatrix},$$

$$\Delta_1 = \begin{vmatrix} n & \sum y_i & \sum x_i^2 \\ \sum x_i & \sum x_i y_i & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^2 y_i & \sum x_i^4 \end{vmatrix}, \quad \Delta_2 = \begin{vmatrix} n & \sum x_i & \sum y_i \\ \sum x_i & \sum x_i^2 & \sum x_i y_i \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^2 y_i \end{vmatrix}.$$

В результате подстановки рассчитанных выборочных сумм ($n = 60$) получены следующие точные значения оценок:

$$b_0 = 2{,}956248, \qquad b_1 = -0{,}123285, \qquad b_2 = 0{,}131396.$$

Итоговое уравнение квадратичной регрессии:

$$\hat{y} = 2{,}9562 - 0{,}1233\,x + 0{,}1314\,x^2.$$

Отрицательный коэффициент b_1 и положительный b_2 означают U-образную параболу с минимумом при $x_{\min} = -b_1/(2b_2) = 0{,}1233/(2 \cdot 0{,}1314) \approx 0{,}469$ ГГц, что лежит вне основного диапазона данных. На практике в диапазоне $x \in [1{,}5;\ 4{,}7]$ ГГц квадратичная кривая монотонно возрастает.

2.3. Степенная модель

Модель имеет вид $y = a \cdot x^b$. Данная спецификация нелинейна, однако её можно линеаризовать логарифмированием обеих частей:

$$\ln y = \ln a + b \ln x.$$

Введём новые переменные $Y = \ln y$ и $X = \ln x$. Тогда уравнение принимает вид парной линейной регрессии:

$$Y = A + bX, \qquad \text{где } A = \ln a.$$

Применение МНК к линеаризованной модели:

$$\hat{b} = \frac{S_{XY}}{S_{XX}}, \qquad \hat{A} = \bar{Y} - \hat{b}\,\bar{X}, \qquad \hat{a} = e^{\hat{A}},$$

где:

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} \ln x_i, \qquad \bar{Y} = \frac{1}{n}\sum_{i=1}^{n} \ln y_i,$$

$$S_{XX} = \sum_{i=1}^{n} (X_i - \bar{X})^2, \qquad S_{XY} = \sum_{i=1}^{n} (X_i - \bar{X})(Y_i - \bar{Y}).$$

По выборочным данным получены следующие численные значения оценок параметров:

$$\hat{b} = 0{,}361024, \qquad \hat{a} = e^{\hat{A}} = 2{,}562085.$$

Итоговое уравнение степенной регрессии:

$$\hat{y} = 2{,}5621 \cdot x^{0{,}3610}.$$

Показатель степени $b = 0{,}361 < 1$ означает, что boost-частота растёт медленнее, чем базовая, — зависимость выпуклая (конкавная). При удвоении базовой частоты boost-частота увеличивается примерно в $2^{0{,}361} \approx 1{,}285$ раза.

2.4. Графики трёх моделей

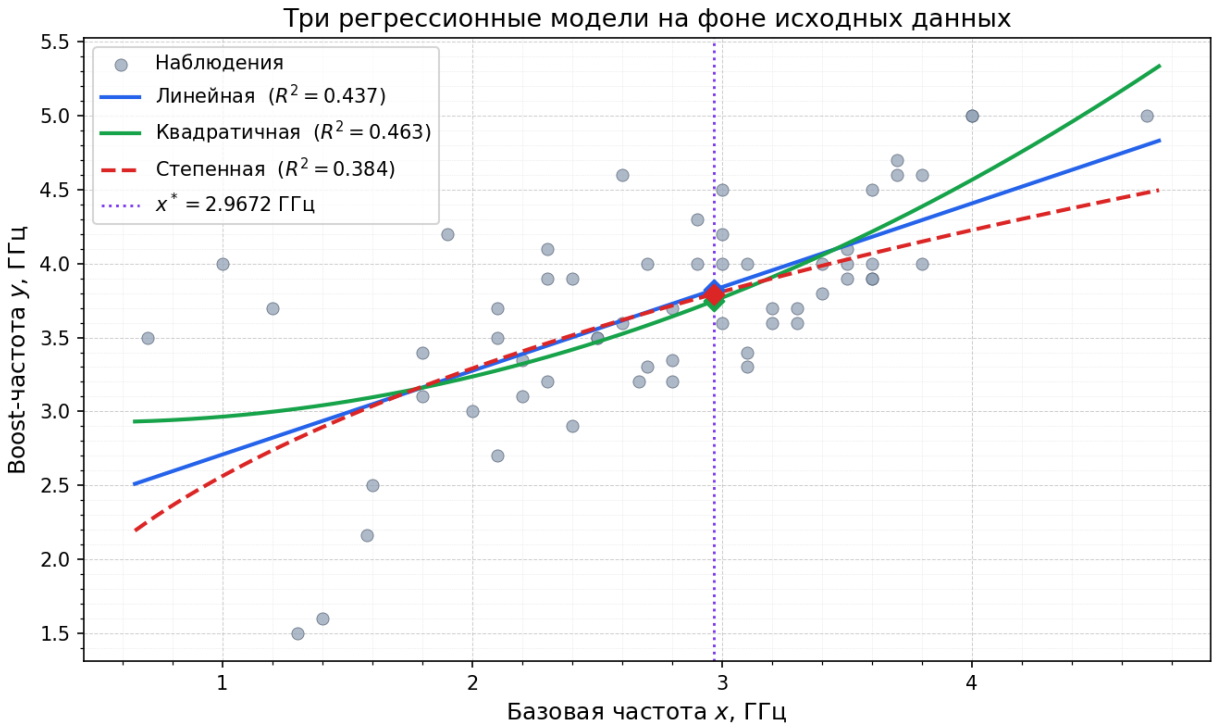


Рис. 2: Три регрессионные модели на фоне исходных данных.

3. Сравнение моделей

Для сравнения моделей используются:

- коэффициент детерминации $R^2 = 1 - \text{RSS}/\text{TSS}$;
- среднеквадратичная ошибка $\text{RMSE} = \sqrt{\text{RSS}/n}$;
- средняя ошибка аппроксимации $A = \frac{100\%}{n} \sum_{i=1}^{n} \left| e_i / y_i \right|$.

Общая сумма квадратов: $\text{TSS} = \sum (y_i - \bar{y})^2 = 29{,}633767$.

Таблица 2: Сравнение моделей по метрикам качества

Модель	R^2	RMSE	A, %	$\hat{y}(x^*)$
Линейная	0,4368	0,5270	13,19	3,8221
Квадратичная	0,4631	0,5145	12,97	3,7473
Степенная	0,3835	0,5513	13,30	3,7942

Наилучшей является **квадратичная модель**: она имеет наибольший $R^2 = 0{,}4631$ и наименьшие RMSE ($0{,}5145$) и A ($12{,}97\%$). Линейная модель незначительно уступает ей. Степенная модель показывает наихудшие результаты по всем трём критериям. Разрыв между моделями невелик, что свидетельствует о значительном влиянии неучтённых факторов (архитектура, техпроцесс, TDP и др.) на boost-частоту.

4. Статистический анализ линейной модели

4.1. Остатки и оценка дисперсии

Прогнозные значения: $\hat{y}_i = 2{,}1422 + 0{,}5662\,x_i$. Остатки: $e_i = y_i - \hat{y}_i$.

Таблица 3: Фрагмент таблицы остатков (первые 20 наблюдений)

i	x_i	y_i	$\hat{y}_i$	e_i	e_i^2
1	0,700	3,500	2,538	0,962	0,925
2	1,000	4,000	2,708	1,292	1,669
3	1,200	3,700	2,821	0,879	0,773
4	1,300	1,500	2,878	−1,378	1,899
5	1,400	1,600	2,935	−1,335	1,782
6	1,580	2,160	3,037	−0,877	0,769
7	1,600	2,500	3,048	−0,548	0,300
8	1,800	3,100	3,161	−0,061	0,004
9	1,800	3,400	3,161	0,239	0,057
10	1,900	4,200	3,218	0,982	0,964
11	2,000	3,000	3,274	−0,274	0,075
12	2,100	3,700	3,331	0,369	0,136
13	2,100	2,700	3,331	−0,631	0,398
14	2,100	3,500	3,331	0,169	0,029
15	2,200	3,100	3,388	−0,288	0,083
16	2,200	3,350	3,388	−0,038	0,001
17	2,300	4,100	3,444	0,656	0,430
18	2,300	3,200	3,444	−0,244	0,060
19	2,300	3,900	3,444	0,456	0,208
20	2,400	3,900	3,501	0,399	0,159
… (ещё 40 наблюдений) …					
				Итого RSS	16,661922

Остаточная сумма квадратов и оценка дисперсии:

$$\mathrm{RSS} = \sum_{i=1}^{n} e_i^2 = 16{,}661922,$$

$$s^2 = \frac{\mathrm{RSS}}{n-2} = \frac{16{,}661922}{58} = 0{,}287275, \qquad s = 0{,}535980.$$

4.2. Стандартные ошибки и доверительные интервалы

$$\mathrm{SE}(\hat{b}) = \frac{s}{\sqrt{S_{xx}}} = \frac{0{,}535980}{\sqrt{52{,}091993}} = 0{,}074289 \approx 0{,}0743,$$

$$\mathrm{SE}(\hat{a}) = s\sqrt{\frac{1}{n} + \frac{\bar{x}^2}{S_{xx}}} = 0{,}535980 \cdot \sqrt{\frac{1}{60} + \frac{2{,}748^2}{52{,}091993}} = 0{,}242710 \approx 0{,}2427.$$

Квантиль распределения Стьюдента: $t_{0{,}975;\,58} = 2{,}002$.

$$95\%\text{ ДИ для } \hat{a}: \quad 2{,}1422 \pm 2{,}002 \cdot 0{,}2427 = [1{,}6577;\ 2{,}6266],$$

$$95\%\text{ ДИ для } \hat{b}: \quad 0{,}5662 \pm 2{,}002 \cdot 0{,}0743 = [0{,}3974;\ 0{,}7350].$$

Таблица 4: Коэффициенты линейной модели

Коэф.	Оценка	SE	$t_{\text{набл}}$	p-знач.	ДИ нижн.	ДИ верхн.
$\hat{a}$	2,1422	0,2427	8,826	$< 0{,}001$	1,6577	2,6266
$\hat{b}$	0,5662	0,0743	6,707	$< 0{,}001$	0,3974	0,7350

4.3. Проверка значимости коэффициента при x

Гипотезы: $H_0 : b = 0$, $H_1 : b \neq 0$, уровень значимости $\alpha = 0{,}05$.

$$t_{\text{набл}} = \frac{\hat{b}}{\mathrm{SE}(\hat{b})} = \frac{0{,}5662}{0{,}0743} = 6{,}7074.$$

Так как $|t_{\text{набл}}| = 6{,}707 > t_{0{,}975;\,58} = 2{,}002$ и $p < 0{,}001$, нулевая гипотеза отвергается. Коэффициент b статистически значим на уровне $0{,}001$. Доверительный интервал для b не содержит ноль, что подтверждает этот вывод.

4.4. Графики остатков

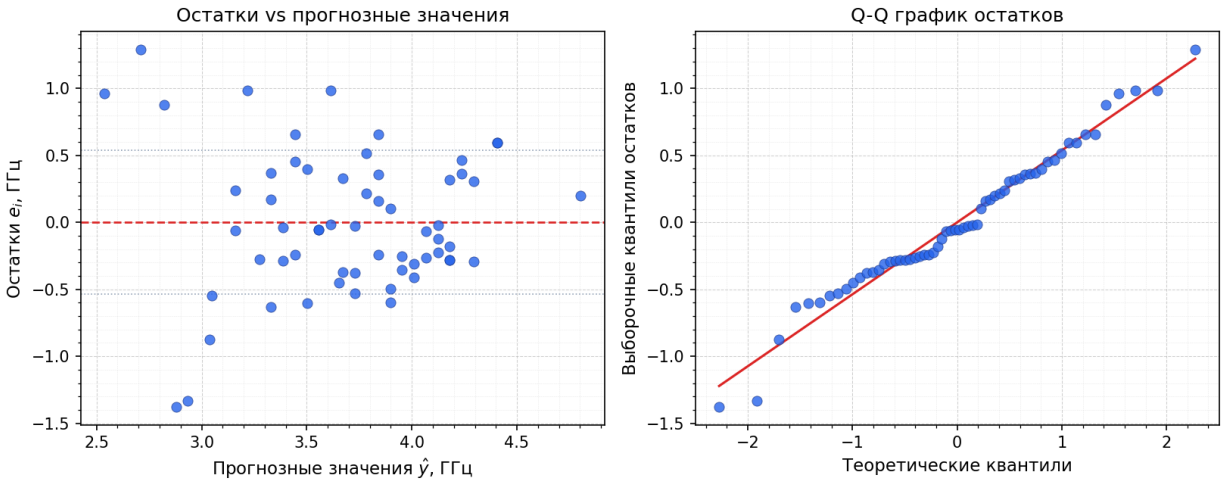


Рис. 3: Слева: остатки против прогнозных значений. Справа: Q-Q график остатков.

На левом графике разброс остатков сравнительно равномерен по всему диапазону прогнозных значений, хотя при малых $\hat{y}$ наблюдается несколько выбросов. Q-Q график показывает умеренное отклонение от

нормальности на хвостах. В целом предположения линейной регрессии выполняются удовлетворительно, однако наличие выбросов и нелинейных эффектов указывает на ограниченность однофакторной модели.

5. Прогноз при $x^* = 2{,}9672$ ГГц

Значение $x^* = 2{,}9672$ ГГц составляет 108% от среднего уровня фактора ($\bar{x} = 2{,}748$ ГГц), $x^* = 1{,}08 \cdot 2{,}748 = 2{,}9672$.

Таблица 5: Прогнозы по трём моделям при $x^* = 2{,}9672$

Модель	$\hat{y}(x^*)$, ГГц
Линейная: $2{,}1422 + 0{,}5662 \cdot 2{,}9672$	3,8221
Квадратичная: $2{,}9562 - 0{,}1233 \cdot x^* + 0{,}1314 \cdot (x^*)^2$	3,7473
Степенная: $2{,}5621 \cdot (2{,}9672)^{0{,}3610}$	3,7942

Для прогноза выбирается **квадратичная модель** как наилучшая по метрикам качества:

$$\hat{y}(2{,}9672) = 2{,}9562 - 0{,}1233 \cdot 2{,}9672 + 0{,}1314 \cdot (2{,}9672)^2 \approx 3{,}7473 \text{ ГГц}.$$

Процессор с базовой частотой 2,97 ГГц ожидаемо имеет boost-частоту около 3,75 ГГц, что соответствует средней части выборки и физически обоснованно. Прогнозы трёх моделей близки друг к другу (разброс менее 0,1 ГГц), что говорит об устойчивости прогноза при данном значении x^*.

6. Итоговый вывод

В работе исследовался набор данных openintro::cpu, содержащий характеристики 60 процессоров, выпущенных в 2010–2020 годах. Изучалась зависимость boost-частоты (ГГц) от базовой тактовой частоты (ГГц).

Были построены три модели: линейная, квадратичная и степенная. По всем трём критериям (R^2, RMSE, MAPE) наилучшей оказалась квадратичная модель ($R^2 = 0{,}463$, RMSE = 0,515, $A = 12{,}97\%$). Линейная модель лишь незначительно уступает ей ($R^2 = 0{,}437$). Степенная модель уступает обеим по всем показателям. Все три модели объясняют менее 47% изменчивости отклика, что свидетельствует о существенном влиянии неучтённых факторов (архитектура, техпроцесс, TDP и др.).

Статистический анализ линейной модели показал высокую значимость коэффициента при x: $t_{\text{набл}} = 6{,}71$, $p < 0{,}001$. Остаточное стандартное отклонение $s = 0{,}536$ ГГц. Доверительный интервал для b составил $[0{,}397;\ 0{,}735]$ и не содержит ноль.

При прогнозном значении $x^* = 2{,}9672$ ГГц квадратичная модель даёт оценку boost-частоты $\approx 3{,}75$ ГГц. Прогнозы всех трёх моделей близки, что указывает на устойчивость вывода. Для повышения точности прогноза рекомендуется расширить набор предикторов (включить количество ядер, TDP, техпроцесс).